

Cuadro Comparativo y Matriz de Decisión de Costos

Evaluación de Modelos para la Automatización de Atención al Cliente

1. Formato Tabla (Cuadro Comparativo)

Tabla comparativa

Modelo	Costo Input (1M)	Costo Output (1M)	Latencia Promedio	Caso de Uso Ideal / Justificación
Google Gemini 1.5 Flash (Seleccionado)	\$0.075 USD	\$0.300 USD	0.8s (Muy Baja)	Clasificación y generación masiva de respuestas a costo mínimo. Excelente relación costo-beneficio para workflows.
OpenAI GPT-4o-mini	\$0.150 USD	\$0.600 USD	1.2s (Baja)	Chatbots conversacionales e inferencia estructurada. Preciso para JSON complejo, pero duplica el costo de Gemini.
Anthropic Claude 3 Haiku	\$0.250 USD	\$1.250 USD	1.0s (Baja)	Análisis de sentimiento y redacción narrativa. Destaca en matices, pero su tarifa de salida es 4x superior a Gemini.

Proyección de Costos Mensuales Estimados

Estimación basada en un volumen de 2,000 correos/mes (Promedio: 500 tokens input / 300 tokens output por interacción):

Modelo	Costo Tokens Input (1M)	Costo Tokens Output (0.6M)	Costo Total Mensual
Gemini 1.5 Flash	\$0.075 USD	\$0.180 USD	\$0.255 USD / mes
GPT-4o-mini	\$0.150 USD	\$0.360 USD	\$0.510 USD / mes
Claude 3 Haiku	\$0.250 USD	\$0.750 USD	\$1.000 USD / mes

2. Formato Lista Estructurada

1. Google Gemini 1.5 Flash (Modelo Seleccionado)

- ✓ Costo Input (Entrada): \$0.075 USD por cada 1,000,000 de tokens.
- ✓ Costo Output (Salida): \$0.300 USD por cada 1,000,000 de tokens.
- ✓ Latencia Promedio: Muy baja (0.8 segundos x consulta).
- ✓ Caso de Uso Ideal y Justificación: Es el modelo óptimo para automatizaciones empresariales de alto volumen que requieren baja latencia y máxima eficiencia en costos. En el flujo planteado, se encarga de analizar el cuerpo del correo, clasificarlo en categorías predefinidas y redactar respuestas estandarizadas manteniendo una altísima precisión operativa a un costo marginal (\$0.25 USD mensuales por cada 2,000 e-mails).

2. OpenAI GPT-4o-mini

- ✓ Costo Input (Entrada): \$0.150 USD por cada 1,000,000 de tokens.

- ✓ Costo Output (Salida): \$0.600 USD por cada 1,000,000 de tokens.
- ✓ Latencia Promedio: Baja (1.2 segundos x consulta).
- ✓ Caso de Uso Ideal y Justificación: Recomendado para asistentes virtuales interactivos y tareas que exigen la extracción de entidades complejas bajo un formato JSON estricto. Se descarta como primera opción debido a que duplica el costo de procesamiento de entrada y salida respecto a Gemini 1.5 Flash sin aportar diferencias significativas en la calidad del texto redactado para atención al cliente.

3. Anthropic Claude 3 Haiku

- ✓ Costo Input (Entrada): \$0.250 USD por cada 1,000,000 de tokens.
- ✓ Costo Output (Salida): \$1.250 USD por cada 1,000,000 de tokens.
- ✓ Latencia Promedio: Baja (1.0 segundo x consulta).
- ✓ Caso de Uso Ideal y Justificación: Especialmente fuerte en comprensión contextual, empatía en la redacción y análisis de sentimientos sobre textos extensos. Se descarta debido a su estructura tarifaria (4.16 veces más costoso en tokens de salida que Gemini 1.5 Flash), lo que incrementa el presupuesto operativo en flujos masivos.

Igualmente, en el resumen del informe se reflejan un resumen de datos.